Linux Kernel Project 3: Memory Management

薛春宇 518021910698

1 实验要求

写一个模块 mtest, 当模块被加载时, 创建一个 proc 文件 /proc/mtest, 该文件接收三种类型的参数, 具体如下:

- listvma: 打印当前进程的所有虚拟内存地址, 打印格式为 start addr end addr permission
- findpage addr: 把当前进程的虚拟地址转化为物理地址并打印,如果不存在这样的翻译,则输出 Error occurred when finding page based on vma...
- writeval addr val: 向当前地址的指定虚拟地址中写入一个值。

注: 所有输出可以用 printk 来完成, 通过 dmesg 命令查看即可。

2 实验环境

Linux OS 版本: Ubuntu 18.04Kernel 版本: Linux-5.5.11

• Gcc 版本: 7.4.0

3 实验内容

本节中,将分别介绍 listvma 、findpage 和 writeval 三个模块的具体实现思路,即涉及到的相关理论知识。此外,我们还将介绍根据用户输入统一调配三个模块的函数 mtest_proc_write(),其同时也是用户空间与 proc 的接口函数。

3.1 模块一: listvma 虚拟内存地址打印

内存描述符 mm struct

在 Linux 中,每个进程都有自己的进程描述符 task_struct ,而当前进程的进程描述符可以从 current 变量获得,该变量定义在 asm/current.h 头文件中,而 task_struct 中的 mm_struct mm 则指向了当前进程的内存描述符。 mm_struct 在 Linux 源码中 /include/linux/mm_types.h 头文件的第 370 行定义,其作用是描述当前进程在 Linux 管理视角下虚拟地址空间的所有信息。以下给出 mm struct 的部分字段:

```
1
    struct mm_struct {
 2
      struct {
 3
        struct vm_area_struct *mmap;
                                       /* list of VMAs */
 4
        struct rb root mm rb;
        // ...
5
        pgd_t * pgd;
 6
7
        // ...
8
       int map count;  /* number of VMAs */
9
        // ...
        spinlock_t page_table_lock; /* Protects page tables and some counters */
10
        struct rw semaphore mmap sem;
11
        // ...
12
13
   };
```

各字段的含义分别为:

- vm_area_struct *mmap: 结构体指针,指向存储虚拟地址空间 VMA 双向链表的节点(将在下一节中详细介绍)
- struct rb_root mm_rb: VMA 红黑树根节点,Linux 使用红黑树存储每个进程的全部 VMA,以提高查找效率
- pgd t *pgd: 页全局目录 Page Global Directory
- int map count: 当前进程对应的 VMA 数目
- spinlock_t page_table_lock: 保护虚拟内存中页表和一些计数变量的自旋锁
- struct rw_semaphore mmap_sem: 读写信号量。由于虚拟内存区域属于系统临界区,在执行读操作时需要加锁。

VMA 双向链表节点 vm_area_struct

vm_area_struct 定义在 include/linux/mm_types.h 头文件的第 292 行,其作用是将进程的虚拟内存地址 VMA 组织成一个双向链表。双向链表中的每个节点均包含该段地址的起止地址 vm_start 和 vm_end,分别指向前后节点的指针 *vm_next 和 *vm_prev,当前进程的内存描述符 *vm_mm,和指示虚拟地址读写权限的 vm flags。在我们实现 listvma 模块时,只需要顺序遍历该链表,读取起止地址和读写权限并打印即可。

```
1
   struct vm area struct {
 2
    unsigned long vm_start; /* Our start address within vm_mm. */
     unsigned long vm end; /* The first byte after our end address within vm mm. */
 3
 4
     /* linked list of VM areas per task, sorted by address */
 5
     struct vm area struct *vm next, *vm prev;
     struct rb node vm rb;
 6
     // ...
7
     struct mm_struct *vm_mm; /* The address space we belong to. */
 8
     unsigned long vm_flags; /* Flags, see mm.h. */
9
10
   };
```

根据 /include/linux/mm.h 中的内容, vm_flags 的低四位表示其读写权限,即 0x1 表示可读, 0x2 表示可写, 0x4 为可执行, 0x8 为可共享。其中, VMA 中与读写权限相关的宏定义在 include/linux/mm.h 的 249~252 行,通过比较 vm_flags 和这些宏的值即可判断读写权限。

```
#define VM_READ 0x00000001 /* currently active flags */
#define VM_WRITE 0x00000002
#define VM_EXEC 0x00000004
#define VM_SHARED 0x00000008
```

listvma 模块的实现

具体实现细节见 Appendix A 中的 mtest_list_vma() 函数。

3.2 模块二: findpage 虚拟地址到物理地址的转换

Linux 分页机制

Linux 中的内存管理采用了分页机制,这个机制从最开始的二级页表,到四级页表,在最近发布的 Linux 内核版本中,分页机制已经升级到五级页表。虚拟地址需要通过页表的一级一级的转换,找到基址所在页的页号,再根据索引找到相应物理地址页帧的页帧号,与偏移量结合得到最后的物理地址。

为了探寻本实验环境下的多级页表类型,我们需要阅读实现页表类型的相关头文件,华为鲲鹏服务器的 arm 架构下,页表类型定义在 arch/arm64/include/asm/pgtable_types.h 内:

```
typedef struct { pteval t pte; } pte t;
   #define pte_val(x) ((x).pte)
 2
   #define __pte(x) ((pte_t) { (x) } )
 3
 4
   #if CONFIG PGTABLE LEVELS > 2
5
   typedef struct { pmdval t pmd; } pmd t;
7
   #define pmd_val(x) ((x).pmd)
   #define __pmd(x) ((pmd_t) { (x) } )
8
9
   #endif
10
   #if CONFIG_PGTABLE_LEVELS > 3
11
   typedef struct { pudval_t pud; } pud_t;
12
   #define pud val(x) ((x).pud)
1.3
14
   #define pud(x) ((pud t) { (x) } )
   #endif
15
16
   typedef struct { pgdval_t pgd; } pgd_t;
17
18
   #define pgd_val(x) ((x).pgd)
   #define \_pgd(x) ((pgd_t) { (x) } )
19
20
```

可以看到,**当前版本下的 Linux 内核仍采用四级页表**。Linux 内存管理四级页表的虚拟地址划分如下:

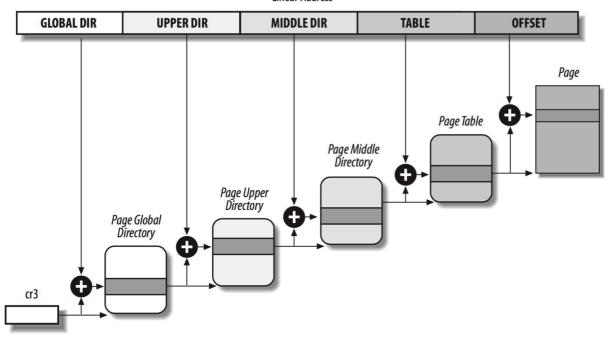
页全局目录	页上级目录	页中级目录	页表	偏移量
pgd (9)	pud (9)	pmd (9)	pte (9)	offset (12)

Linux 从虚拟地址到物理地址的转换

四级页表的物理地址转换过程如下:

- 从当前进程的进程描述符 task_struct 中的 pgd 字段获取页全局目录 pgd 的基址,可通过 pgd offset(mm, addr) 函数实现;
- pgd 基址 + 虚拟地址中的 pgd 字段 = pud 基址, 可通过 pud_offset(pgd, addr) 函数实现;
- pud 基址 + 虚拟地址中的 pud 字段 = pmd 基址, 可通过 pmd offset(pud, addr) 函数实现;
- pmd 基址 + 虚拟地址中的 pmd 字段 = pte 基址, 可通过 pte_offset_map(pmd, addr) 函数实现;
- pte 基址 + 虚拟地址中的 pte 字段 = page 基址, 可通过 pte page(*pte) 函数实现;
- page 基址 + 虚拟地址中的 offset 字段 = 物理地址, 可通过 page_to_phys(page) 函数实现。





findpage 模块的实现

在上述地址转换过程中,pgd_offset、pud_offset 等函数,包括 pte_offset_map 和 pte_page,均在 arch/arm64/include/asm/pgtable.h 通过宏的形式定义和实现,以 pgd 为例,计算时将 pgd 基址与偏移量 pgd index(addr) 相加,函数返回 pgd t * 类型的指针。

```
/* to find an entry in a page-table-directory */
#define pgd_index(addr) (((addr) >> PGDIR_SHIFT) & (PTRS_PER_PGD - 1))
#define pgd_offset_raw(pgd, addr) ((pgd) + pgd_index(addr))
#define pgd_offset(mm, addr) (pgd_offset_raw((mm)->pgd, (addr)))
```

pte_page(*pte) 函数的返回值是页描述符 struct *page page, 到此步为模块二的第一部分, 我们将这部分单独封装为一个函数 find_page_based_on_vma(vma, addr), 同时供模块三 writeval 的调用。注意到并非所有的虚拟地址都会对应 pgd 等页表层级,因此需要检查上述函数返回的指针是否有效,并利用 pgtable.h 中提供的 pgd none()和 pgd bad()等函数进行指针的检查。

模块二的第二部分被实现为 mtest find page(addr), 依次实现以下内容:

• 调用 find_vma(current->mm, addr) 函数,利用当前进程的内存描述符和输入的 addr,查找存储相应虚拟地址的双向链表结构体 vm area struct,该函数在 /mm/mmap.c 文件中实现,遍历当前虚拟内存所在的

```
1
    /* Look up the first VMA which satisfies addr < vm_end, NULL if none. */
2
    struct vm_area_struct *find_vma(struct mm_struct *mm, unsigned long addr) {
 3
      struct rb node *rb node;
      struct vm area struct *vma;
 4
 5
      // ...
 6
      while (rb_node) {
 7
        struct vm_area_struct *tmp;
8
        tmp = rb_entry(rb_node, struct vm_area_struct, vm_rb);
9
        if (tmp->vm_end > addr) {
10
          vma = tmp;
11
         if (tmp->vm start <= addr)</pre>
            break;
12
13
          rb node = rb node->rb left;
14
        } else
15
          rb_node = rb_node->rb_right;
16
      }
      // ...
17
      return vma;
18
19
   }
```

- 调用部分一实现的 find_page_based_on_vma(vma, addr) 函数,利用当前进程的 vma 和输入的 addr, 查找虚拟地址所对应的页,若 page 为空则报错并返回;
- 基于上一步中函数返回的页描述符 page ,调用 page_to_phys(page) 函数,将虚拟地址对应的页转化为物理地址对应的页帧,并与使用 PAGE_MASK 进行 addr 位过滤得到的 offset 字段结合,得到最终的物理地址。

具体实现细节见 Appendix B 中的 find_page_based_on_vma() 和 mtest_find_page() 函数。

3.3 模块三: writeval 写入指定虚拟地址

内核态虚拟地址空间

当进程要向指定的地址写数据时,所使用的虚拟地址来自于进程私有的虚拟地址空间。然而,当我们调用内核模块来向指定的地址写入数据时,所使用的虚拟地址则来自于内核态共享的虚拟地址空间,两套空间互相独立。因此,为了使用内核模块修改用户态进程中指定的虚拟地址上的值,我们需要首先将该用户态虚拟地址转化为物理地址,再将该物理地址映射到内核态虚拟地址空间。

writeval 模块的实现

本模块被实现为 mtest_write_val(addr, val) 函数, 依次实现以下内容:

- 调用 find_vma(current->mm, addr) 函数,利用当前进程的内存描述符和输入的 addr, 查找存储相应虚拟地址的双向链表节点 vm area struct。若返回的 vma 指针为空或不可写,则报错并返回;
- 调用 3.2 节中实现的 find_page_based_on_vma(vma, addr) 函数, 利用当前进程的 vma 和输入的 addr, 查找虚拟地址所对应的页, 若 page 为空则报错并返回;

• 调用 page_address(page) 函数,将物理地址对应的 page 转化为内核态虚拟地址 kernel_addr,注意到与之前地址的声明不同的是,这里的 kernel_addr 需要被声明为指针,以供后续值的写入。值的写入可以通过 *kernel addr=val;实现,完成写入后将相关信息通过 dmesg 打印到系统信息中。

具体实现细节见 Appendix C 中的 mtest write val() 函数。

3.4 proc 接口函数的实现

在 proc 接口函数 mtest_proc_write(*file, *buffer, count, *data) 内,我们首先调用函数 copy_from_user(proc_buf, buffer, count),将储存在 buffer 内的用户空间内的输入 copy 到内核空间里的全局 buffer proc_buf 内,count 是输入总字符数,且若函数返回值非 0,则报错并返回。之后,我们调用 /include/linux/string.h 头文件内定义的 strcmp() 字符串比较函数,判断输入需要执行哪一个模块,并分别调用相应的函数即可。

```
// Implement the interface of proc file, different echo -> different operations
   static ssize t mtest proc write(struct file *file, const char user * buffer,
    size t count, loff t * data) {
      // Address
 3
      unsigned long int addr;
 4
5
      // Value for write
      unsigned long int value;
 6
 7
8
      // Copy from user buffer
9
      int copy return msg = copy from user(proc buf, buffer, count);
10
      if(copy return msg != 0) {
        printk(KERN_ERR "Error occurred when copying from user...\n");
11
12
            return -EFAULT;
13
      if (strncmp(proc_buf, "listvma", 7) == 0) {
14
        printk(KERN_INFO "Operation: listvma\n");
15
        mtest list vma();
16
17
18
      else if(strncmp(proc buf, "findpage", 8) == 0) {
19
        // Addr input
        sscanf(proc_buf + 9, "%lx", &addr);
20
21
22
        printk(KERN INFO "Operation: findpage 0x%lx\n", addr);
23
        mtest find page(addr);
2.4
25
      else if(strncmp(proc buf, "writeval", 8) == 0) {
26
        // Addr and value input
        sscanf(proc_buf + 9, "%lx %ld", &addr, &value);
27
28
        printk(KERN_INFO "Operation: writeval 0x%lx with %ld\n", addr, value);
        mtest write val(addr, value);
2.9
30
      }
31
      else {
        printk(KERN ERR "Error occurred when getting input...\n");
32
33
      }
```

```
34   return count;
35 }
```

4 实验结果及分析

4.1 Makefile 及编译、内核载入

编写如下 Makefile, 并使用 make 指令对 mtest.c 文件进行编译:

```
obj-m := mtest.o

KDIR := /lib/modules/$(shell uname -r)/build

PWD := $(shell pwd)

all:
    make -C $(KDIR) M=$(PWD) modules

clean:
    rm *.o *.ko *.mod.c *.mod Module.symvers modules.order -f
```

完成编译后,执行 [insmod mtest.ko] 指令将内核模块插入到内核态中,并使用 [lsmod | grep mtest] 查看模块是否已经加载成功。

4.2 模块一: listvma

使用如下指令进行测试:

```
1 echo listvma > /proc/mtest
```

相应的输出如上图。可以发现,有大量虚拟地址位于 0xffff80000000 之后,这段区域是 64bit Linux 的内核虚拟地址空间,进程有大量虚拟地址位于该空间内。

4.2 模块二: findpage

从模块一的输出结果中选取一个 vma 作为模块二测试的输入,使用如下指令进行测试:

```
1 echo findpage 0xffffa1829000 > /proc/mtest
```

从下图中的输出可知,模块成功找到该虚拟地址对应的页,虚拟地址 0xffffa1829000 对应的物理地址为 0x5ad4c000:

```
[ 6214.117618] Operation: findpage 0xffffa1829000
[ 6214.117621] Virtual Address: 0xffffa1829000 -> Physical Address: 0x5ad4c000
```

当随机查找一个未被使用的虚拟地址时,模块则会输出 Error 信息,原因是页起始地址 pte 无效:

```
[ 6265.958543] Operation: findpage 0xffffa2729000
[ 6265.958545] Error occurred when finding page based on vma...
```

4.3 模块三: writeval

仍然从模块一的输出结果中选取一个可写的 vma 作为模块三输入的地址,并选择值 666 ,使用如下指令进行模块三的测试:

```
echo writeval 0xffffa1812000 666 > /proc/mtest
```

从下图的输出可知,模块成功将值 666 写入虚拟地址 0xffffa1812000 对应的存储空间内:

```
[ 6528.816132] Operation: writeval 0xffffa1812000 with 666
[ 6528.816135] Successfully write 666 into virtual address: 0xffffa1812000
```

接下来,从模块一的输出中选取一个读写权限为不可写的 vma 0xffffa1829000 作为输入的地址,则会得到 Error occurred when writing to an unwritable page... 的报错:

```
[ 6340.146198] Operation: writeval 0xffffa1829000 with 666
[ 6340.146200] Error occurred when writing to an unwritable page...
```

最后,当我们尝试写入一个未被使用的虚拟地址 0xffffa17f6000 时,模块得到报错 Error occurred when finding page based on vma...:

```
[ 6464.114053] Operation: writeval 0xffffa17f6000 with 666 [ 6464.114556] Error occurred when finding page based on vma...
```

5 实验心得

本次实验是 Linux 内核课程的第三次正式 project,旨在掌握面向 Linux 进程的内存管理,包括虚拟内存的打印、转换为物理地址以及特定地址的值写入。在模块一 listvma 的实现过程中,我通过阅读源码的方式深入分析了 Linux 内存描述符的相关字段,并通过阅读 vm_area_struct 结构体的具体实现了解了虚拟内存区间双向链表的组织形式,以及 vm_flags 所表示的虚拟地址区间的读写权限;同时,在实现 findpage 和 writeval 模块的过程中,我初步理解了 Linux 内核的分页机制和虚拟地址到物理地址的转换机制,并掌握了对特定地址进行值修改

的方法。

在实验过程中,我首先根据实验指导书上的提示,通过关键词匹配的方式分别找到了几个关键结构体的源码实现,并依次进行调用函数的深入搜索、研究,最终细化到底层实现,力求完全掌握该结构体的功能及所调用函数的意义。由于目前网上针对 Linux 内核管理模块的教程大多质量参差不齐,且内核版本也浮动较大,因此我必须不断进行试错,不断修改报错的 API 或结构体类名。例如,在本机上的 Ubuntu 20.04 中,内核的文件结构体对应的类名是 proc_ops,但当我从虚拟机上将代码移植到华为鲲鹏服务器上时,/proc 接口处却报错 proc_ops 不含有成员 .proc_write ,在经过一番搜索后仍未找到解决方案,最后尝试将文件结构体修改为 file_operations ,成功跑通,当前版本的 Kernel 中 linux/proc_fs.h 支持的文件结构体类型时 file_operations 而非 proc_ops。

在服务器上进行实验的时候,dmesg 时总会看见系统报出大量的报错,在华为云的开发者论坛中搜索后得知,这是当前华为鲲鹏服务器升级到 Ubuntu20.04 后存在的一个已知的内核问题,暂时无法解决。Ref: 鲲鹏服务器一直系统报错

```
[drm:virtio_gpu_dequeue_ctrl_func [virtio_gpu]] *ERROR* response 0x1202 (command 0x103)
```

本次实验中,我不仅更深一步地掌握了 *Linux* 源码阅读的方法,增强了自身阅读源码的能力,还提高了发现问题、解决问题的能力。希望能在下面的实验中也能收获满满!

Appendix A: listvma 代码实现

```
/*Print all vma of the current process*/
 1
 2
   static void mtest_list_vma(void) {
 3
      // Pointer to the linked list in virtual memory
 4
      struct vm area struct *cur = current->mm->mmap;
 5
      printk(KERN INFO "Current process ID: %d", current->pid);
 6
7
      while(cur) {
        // Permission
8
        char permission[5] = "---";
9
10
11
        // Read
        if(cur->vm_flags & VM_READ) {
12
          permission[0] = 'r';
13
14
        }
        // Write
15
16
        if(cur->vm flags & VM WRITE) {
17
          permission[1] = 'w';
18
        }
19
        // Execute
        if(cur->vm_flags & VM_EXEC) {
2.0
21
          permission[2] = 'x';
22
        }
```

```
23
        // Shared or not
24
        if(cur->vm_flags & VM_SHARED) {
2.5
          permission[3] = 's';
26
        } else {
27
          permission[3] = 'p';
28
29
        printk(KERN_INFO "0x%lx 0x%lx %s\n", cur->vm_start, cur->vm_end, permission);
3.0
        cur = cur->vm_next;
31
32
      }
    }
33
```

Appendix B: findpage 代码实现

```
/* Find the corresponding page based on the vma */
   static struct page* find_page_based_on_vma(struct vm_area_struct* vma, unsigned
    long addr) {
      // Memory descriptor of current process
3
      struct mm_struct *mm = vma->vm_mm;
 4
      // Page global directory
 5
      pgd_t *pgd = pgd_offset(mm, addr);
 6
 7
      // // Page 4 directory (new to 5 levels page table in Linux)
8
      // p4d t *p4d = NULL;
9
      // Page upper directory
      pud t *pud = NULL;
10
11
     // Page middle directory
12
      pmd_t *pmd = NULL;
      // Page table
13
      pte_t *pte = NULL;
14
15
      // Page
      struct page *page = NULL;
16
17
      // Check and assignment
18
      if(pgd_none(*pgd) || pgd_bad(*pgd)) { return NULL; }
19
20
      // // Assign to p4d
21
      // p4d = p4d offset(pgd, addr);
2.2
23
      // if(p4d_none(*p4d) || p4d_bad(*p4d)) { return NULL; }
24
      // Assign to pud
25
      pud = pud_offset(pgd, addr);
26
      if(pud_none(*pud) | pud_bad(*pud)) { return NULL; }
27
28
      // Assign to pmd
29
      pmd = pmd offset(pud, addr);
30
31
      if(pmd none(*pmd) | pmd bad(*pmd)) { return NULL; }
32
      // Assign to pte
```

```
33
      pte = pte offset map(pmd, addr);
34
35
      if(pte none(*pte) | !pte present(*pte)) { return NULL; }
36
      // Page
37
      page = pte_page(*pte);
      if(!page) { return NULL; }
38
39
      pte_unmap(pte);
40
      return page;
41
42
43
44
    /*Find va->pa translation */
45
    static void mtest_find_page(unsigned long addr) {
46
      // Page
47
      struct page *page = NULL;
      // Physical address
48
      unsigned long physical addr;
49
50
      // Find vma
51
52
      struct vm_area_struct *vma = find_vma(current->mm, addr);
53
      if(!vma) {
        printk(KERN ERR "Error occurred when finding vma...\n");
54
        return;
55
56
      }
57
58
      page = find_page_based_on_vma(vma, addr);
59
      if(!page) {
60
        printk(KERN_ERR "Error occurred when finding page based on vma...\n");
61
        return;
62
      }
63
64
      physical_addr = page_to_phys(page) | (addr & ~PAGE_MASK);
      printk(KERN_INFO "Virtual Address: 0x%lx -> Physical Address: 0x%lx\n", addr,
    physical_addr);
66
    }
```

Appendix C: writeval 代码实现

```
1
   /*Write val to the specified address */
2
   static void mtest_write_val(unsigned long addr, unsigned long val) {
     // Page
3
4
     struct page *page = NULL;
5
     // Virtual addr in kernel space
6
     unsigned long *kernel_addr;
7
8
     // Find vma
9
     struct vm_area_struct *vma = find_vma(current->mm, addr);
```

```
if(!vma) {
10
11
        printk(KERN_ERR "Error occurred when finding vma...\n");
12
        return;
13
      }
14
15
      // If vm cannot be written
     if(!(vma->vm_flags & VM_WRITE)) {
16
17
       printk(KERN_ERR "Error occurred when writing to an unwritable page...");
       return;
18
19
      }
20
21
      page = find_page_based_on_vma(vma, addr);
     if(!page) {
22
       printk(KERN_ERR "Error occurred when finding page based on vma...\n");
23
24
        return;
25
     } else {
        kernel addr = (unsigned long *)page address(page);
26
27
        // Modify the value
        *kernel_addr = val;
28
        printk(KERN_INFO "Successfully write %ld into virtual address: 0x%lx\n", val,
29
    addr);
     }
30
31
    }
```